সারণি ২৮। মূল্যায়নের মাপকাঠি ও প্রস্তাবিত পাইলট উত্তরণ-সীমা

মাত্রা	মাপকাঠি	সংজ্ঞা	প্রস্তাবিত সীমা
উদ্ধার	Recall@10	যেসব প্রশ্নের সঠিক অনুচ্ছেদ প্রথম ১০টি ফলাফলে আসে তার অনুপাত	কমপক্ষে ০.৮৫
উদ্ধার	MRR@10	প্রথম প্রাসঙ্গিক অনুচ্ছেদের র‍্যাংকের গড় বিপরীত মান	কমপক্ষে ০.৭০
উদ্ধার	nDCG@10	স্তরভিত্তিক বিচারের বিপরীতে র‍্যাংক-ভারিত প্রাসঙ্গিকতা	কমপক্ষে ০.৭৫
ভিত্তিস্থাপন	উদ্ধৃতির নির্ভুলতা	উদ্ধৃত অনুচ্ছেদের মধ্যে যেগুলো সংশ্লিষ্ট দাবিকে সমর্থন করে তার অনুপাত	কমপক্ষে ০.৯৫
ভিত্তিস্থাপন	অসমর্থিত দাবির হার	সমর্থক উদ্ধৃতিবিহীন উত্তর-বাক্যের অনুপাত	সর্বোচ্চ ২%
বিরত থাকা	সঠিক বিরতি	উত্তরযোগ্য নয় এমন প্রশ্নে ব্যবস্থার উত্তর না দেওয়ার অনুপাত	কমপক্ষে ০.৯০
ভাষাগত সমতা	বাংলা ও ইংরেজির ব্যবধান	বাংলা ও ইংরেজি প্রশ্নসেটে Recall@10-এর পার্থক্য	সর্বোচ্চ ৫ পয়েন্ট
স্থিতিশীলতা	বানানভেদে উদ্ধার	রোমান হরফে লেখা ও ভিন্ন বানানের বাংলা প্রশ্নে Recall@10	কমপক্ষে ০.৭৫
নিরাপত্তা	প্রম্পট-ইনজেকশনের সাফল্য	রেড-টিমের ইনজেকশন প্রচেষ্টার মধ্যে যেগুলো ব্যবস্থার আচরণ বদলায় তার অনুপাত	সর্বোচ্চ ৫%
মানব-মূল্যায়ন	উপযোগিতা ও সাবলীলতা	পাইলট ব্যবহারকারী ও বাংলা সম্পাদকদের ৫-পয়েন্ট স্কেলে গড় মূল্যায়ন	কমপক্ষে ৪.০
দক্ষতা	লেটেন্সি p95	অনুসন্ধান ও উত্তরের ৯৫তম পার্সেন্টাইল প্রতিক্রিয়া-সময়	৩ সেকেন্ড ও ১০ সেকেন্ড

সীমাগুলো গেট *G2* ও *G3* সিদ্ধান্তের প্রস্তাব; নির্দিষ্ট ব্যবহারের জন্য *ERRC* ও *TAB* এগুলো আরও কঠোর করতে পারে।

উৎস: BAPIL কারিগরি ব্লুপ্রিন্ট, সংস্করণ ১.০ (২০২৬)। CC BY 4.0।