সারণি ৬৩। মূল্যায়ন প্রটোকল ও রিলিজ-গেটের নিয়ম

পরিমাপ	সংজ্ঞা	পরীক্ষা-সেট ও নমুনা	পদ্ধতি ও দায়িত্ব	সিদ্ধান্ত-নিয়ম
Recall@10, MRR@10, nDCG@10	প্রতিটি উত্তরযোগ্য প্রশ্নে কোনো সঠিক অনুচ্ছেদ প্রথম ১০টিতে থাকলে সফল; সফলতার গড়ই Recall@10। MRR ও nDCG সারণি ২৮ অনুযায়ী	ব্যক্তিগত পরীক্ষা-অংশ: v0-তে কমপক্ষে ৩০০টি উত্তরযোগ্য প্রশ্ন (প্রতি ভাষায় প্রায় ১৫০টি) এবং v1-এ ১,২০০টি	মূল্যায়ন দলের স্বয়ংক্রিয় স্কোরিং; স্ক্রিপ্ট, ফলাফল, কনফিগারেশন ও কর্পাস সংস্করণ সংরক্ষিত	বিন্দু-প্রাক্কলন সীমা অর্জন করলে এবং ৯৫% ব্যবধান ধনাত্মক-ঋণাত্মক ৫ পয়েন্টের বেশি চওড়া না হলে সীমা অর্জিত (n = ৩০০-এ প্রায় ৪ পয়েন্ট); অন্যথায় সিদ্ধান্তের আগে আরও প্রশ্ন টীকাকরণ
উদ্ধৃতির নির্ভুলতা	নমুনাভুক্ত উত্তর-বাক্যের মধ্যে যেগুলোর উদ্ধৃত অনুচ্ছেদ বাক্যটিকে পুরোপুরি সমর্থন করে তার অনুপাত (সমর্থিত, আংশিক সমর্থিত বা অসমর্থিত; শুধু সমর্থিত গণ্য)	পরীক্ষা-উত্তর থেকে দৈবভাবে নেওয়া ৪০০টি উত্তর-বাক্য, প্রতি ভাষায় কমপক্ষে ২০০টি	ব্যবস্থার সংস্করণ না জানা দুজন প্রশিক্ষিত টীকাকার; তৃতীয়জন নিষ্পত্তি করেন; কোহেনের কাপ্পা প্রতিবেদিত (লক্ষ্য ০.৭০ বা তার বেশি)	বিন্দু-প্রাক্কলন কমপক্ষে ০.৯৫ (n = ৪০০-এ ব্যবধান প্রায় ধনাত্মক-ঋণাত্মক ২ পয়েন্ট)
অসমর্থিত দাবির হার	নমুনাভুক্ত বাক্যের মধ্যে যেগুলো কোনো উদ্ধারকৃত অনুচ্ছেদ দ্বারা সমর্থিত নয় তার অনুপাত	উদ্ধৃতির নির্ভুলতার একই নমুনা	একই টীকাকার	বিন্দু-প্রাক্কলন সর্বোচ্চ ২%
সঠিক বিরতি ও উত্তর-আওতা	আওতাবহির্ভূত প্রশ্নে বিরতি; উত্তরযোগ্য প্রশ্নে উত্তর	v0-তে ১৫০টি আওতাবহির্ভূত পরীক্ষা-প্রশ্ন (রচিত ২০০টি: উন্নয়নে ৫০, পরীক্ষায় ১৫০); সব উত্তরযোগ্য পরীক্ষা-প্রশ্ন	স্বয়ংক্রিয়	বিরতি কমপক্ষে ০.৯০ (ব্যবধান প্রায় ধনাত্মক-ঋণাত্মক ৫ পয়েন্ট); আওতা কমপক্ষে ০.৮০
ভাষাগত সমতা	ইংরেজির Recall@10 বিয়োগ বাংলার Recall@10, বুটস্ট্র্যাপ ব্যবধানসহ	ভাষাভিত্তিক পরীক্ষা-উপসেট	স্বয়ংক্রিয়	v0-তে প্রতিবেদিত, কারণ ব্যবধান সিদ্ধান্তের জন্য বেশি চওড়া; v1 থেকে রিলিজের শর্ত
স্থিতিশীলতা	ভিন্ন বানান ও রোমান হরফের প্রশ্নে, OCR-নির্ভর নথিতে উত্তরযুক্ত প্রশ্নে এবং মিশ্র-ভাষার প্রশ্নে Recall@10	যথাক্রমে কমপক্ষে ১০০, ১০০ ও ৫০টি পরীক্ষা-প্রশ্ন	স্বয়ংক্রিয়	ভিন্ন বানানে কমপক্ষে ০.৭৫; বাকি দুটি v0-তে গেট ছাড়া প্রতিবেদিত
প্রম্পট-ইনজেকশন ও নিষিদ্ধ ফলাফল	রেড-টিমের প্রচেষ্টার (নথি বা প্রশ্নে লুকানো নির্দেশ) মধ্যে যেগুলো আচরণ বদলায় তার অনুপাত; নিষিদ্ধ ফলাফলের অনুরোধ	কমপক্ষে ১০০টি প্রচেষ্টা, প্রতি রিলিজে হালনাগাদ	নিরাপত্তা প্রধান ও একটি বহিস্থ রেড-টিম	সর্বোচ্চ ৫%; অ-উন্মুক্ত ডেটার যেকোনো ফাঁস অনুত্তীর্ণ
গোপনীয়তা	লগ, ফলাফল বা মূল্যায়ন-সেটে P2 বা P3 ডেটার উপস্থিতি; প্রবেশাধিকার-নিয়ন্ত্রণ পরীক্ষা	লগের নমুনা ও স্বয়ংক্রিয় স্ক্যান	শাসন বিশ্লেষক; বার্ষিক স্বাধীন নিরীক্ষা	শূন্য অনুসন্ধান-ফল
লেটেন্সি ও প্রাপ্যতা	p95 প্রতিক্রিয়া-সময়; কর্মঘণ্টার যে অংশে সেবা চালু	G2-তে ৩০ জন একযোগে ব্যবহারকারীসহ চাপ-পরীক্ষা; G3 চলাকালে পর্যবেক্ষণ	প্ল্যাটফর্ম প্রধান	অনুসন্ধানে ৩ সেকেন্ড ও উত্তরে ১০ সেকেন্ড; কমপক্ষে ৯৯%
উপযোগিতা	৫-পয়েন্ট স্কেলে গড় মূল্যায়ন	কমপক্ষে ৩০ জন পাইলট ব্যবহারকারী; বাংলা সম্পাদকদের মূল্যায়িত কমপক্ষে ১০০টি উত্তর	প্রোডাক্ট ওনার ও মূল্যায়ন দল	কমপক্ষে ৪.০
P2 নিষ্কাশনের নির্ভুলতা	নিষ্কাশিত সারণি-ঘরের মধ্যে যেগুলো মূল নথির সঙ্গে মেলে তার অনুপাত	বছর ও মন্ত্রণালয়জুড়ে স্তরভিত্তিক দৈবচয়িত কমপক্ষে ১,০০০টি ঘর	দুজন স্বাধীন যাচাইকারী	কমপক্ষে ৯৯% (ব্যবধান প্রায় ধনাত্মক-ঋণাত্মক ০.৬ পয়েন্ট)
প্রমাণ-প্রাপ্তির সময়	সমতুল্য কাজে সরঞ্জামসহ ও সরঞ্জাম ছাড়া প্রামাণ্য প্রমাণ খুঁজে উদ্ধৃত করার মধ্যক সময়	কমপক্ষে ২০ জন বিশ্লেষক, প্রত্যেকে ৬টি কাজ, ক্রসওভার নকশা	মূল্যায়ন দল; মাস ১৮-এ স্বাধীন মূল্যায়নকারী	প্রভাব ও ব্যবধান প্রতিবেদিত; G4-কে তথ্য দেয়, G3-তে উত্তীর্ণ-নম্বর নেই
পুনরুৎপাদনযোগ্যতা	ব্যক্তিগত অংশে সংরক্ষিত ফলাফলের পুনঃস্কোরিং	গেট-সিদ্ধান্তে ব্যবহৃত প্রতিটি রিলিজ	G4-এর আগে স্বাধীন মূল্যায়নকারী	পুনঃস্কোরকৃত মাপকাঠি প্রতিবেদিত মানের ১ পয়েন্টের মধ্যে

ব্যবধানগুলো ৯৫% উইলসন বা বুটস্ট্র্যাপ ব্যবধান। *BanglaPolicyQA v0*-তে ৫০০টি উত্তরযোগ্য প্রশ্ন *(৪০% উন্মুক্ত উন্নয়ন-অংশ, ৬০% ব্যক্তিগত পরীক্ষা-অংশ)* ও ২০০টি আওতাবহির্ভূত প্রশ্ন আছে। নমুনার আকার ন্যূনতম; *T2* স্তরের ব্যবহারে *ERRC* ও *TAB* আরও বেশি চাইতে পারে।

উৎস: BAPIL কারিগরি ব্লুপ্রিন্ট, সংস্করণ ১.০ (২০২৬)। CC BY 4.0।